

— 科研重构报告 · HUMAN REVIEW EDITION

FME 单一科研主线 重构与 RQ1-RQ4 验证

Refactor0830 · 从分散探索路线收敛到可证伪的多问题算法研究闭环

agent_ad · Refactor0830

V1.0 · 2026-08-30

人审 / 对外沟通版

| 目录

01	执行摘要
02	收敛后的完整主线
03	研究问题与评价协议
04	RQ1-RQ4 证据结果
05	算法潜力，而不只是末次得分
06	模型配置与在线阻塞
07	结论、边界与下一步
A	复现索引与参考文献

| 执行摘要

本轮重构已经把活跃科研面收敛为一条主线：**FME 是唯一科学控制器**，EOH 负责候选生成，RAG / 历史库负责受边界约束的证据冷启动，BP、TSP、CVRP 由统一问题适配器接入。已有证据足以否定若干过强假设，但尚不足以宣称在线跨模型收益。

给评审者的四句话

- 1. 主线已收敛：不再把 EOH、RAG、TOCC、router、selector 各自当成独立科研路线；它们只在能改善反馈、记忆、泛化、质量或复现时作为适配器存在。
- 2. RQ1 出现负证据：历史 BP 配对证据中，FME 机制记录更完整，但有效候选率从 73.3% 降至 23.3%，不能宣称质量提升。
- 3. RQ2 有问题依赖的方向性信号：结果感知历史检索相对纯检索在 TSP 与 CVRP 的中位改进分别为 0.83% 与 5.95%；历史数据缺少 shuffled control，因此只能作方向性结论。
- 4. RQ4 在线实验被外部权限阻塞：Model Router 连接与鉴权路径可达，但 DeepSeek V4 Flash 预检返回 HTTP 403(模型符号不存在或账号无权限)；报告不会把历史异协议 cohort 拼成跨模型因果结论。

DECISION

继续投入的是“可证伪的算法研究闭环”，不是更多并列框架。下一笔模型预算应在同一冻结协议下补齐 prospective analysis 与 cross-model cohort，而不是延长任意固定的 8 代。

收敛后的完整主线

一个控制器、三类适配器、两条潜力曲线、一道 held-out 边界，构成完整且可审计的研究叙事。




图 1: Refactor0830 的活跃科研面。红色虚线代表严格边界或当前外部阻塞。

保留什么，为什么保留

组成	在主线中的唯一职责	保留门槛
FME Research Loop	统一问题栈、动作选择、证据更新、反例与决策	必须形成可证伪 claim 与证据边界
EOH	候选算法生成、变异与反思提示	只作为 CandidateGeneratorAdapter
RAG / 历史库	注入相关文献、历史进化、失败经验与抽象迁移证据	有冻结快照、引用哈希、held-out 隔离
ProblemAdapter	把 BP-online、TSP、CVRP 变成可比的生成-评估接口	统一预算单位与 cohort 口径
模型 Provider	可替换的算法生成 / 分析模型	同协议比较，不能混用历史 cohort

EOH 和 RAG 仍然需要，但不再“统治主线”。EOH 回答“如何产生候选”，RAG 回答“允许给候选生成器看什么”；科学问题、可比性与是否继续由 FME 决定。

| 研究问题与评价协议

研究对象不是“某个提示能否偶然跑高分”，而是系统是否更快、更稳、更可解释地发现具有算法潜力的机制。

RQ	核心对比	主要指标	本轮证据类型
RQ1	标量反馈 vs 结构化被动分析 vs FME 主动反思	质量、有效候选率、反例与机制 claim	冻结历史配对重放
RQ2	无历史 vs 相关历史 vs shuffled history	相对改进、达到阈值预算、污染检查	历史消融；缺 shuffled arm
RQ3	无迁移 vs 仅抽象机制迁移	跨问题 win/tie/loss、稳定性	不完整配对重放
RQ4	Controller × Model 的冻结 2×2 比较	模型主效应、控制器主效应、交互效应	历史单模型 + 在线预检

为什么不是固定 8 次算法生成

未找到支持“8 次 / 8 代具有普适最优性”的文献依据。EoH 报告的典型设置约为 20 代与约 2,000 次 LLM 查询；ReEvo 使用 30 个初始候选与 100 次评估预算；FunSearch、EPS 等工作也使用随任务变化的预算。由此，本项目把 8 代降级为历史工程设置，正式口径改为：

BUDGET RULE

横轴统一使用可核对的候选评估数或模型调用数；报告完整的 anytime curve、阈值到达预算与 normalized AUC。达到预算、证据饱和或失败退出条件任一项即停，而不是为了凑固定代数继续生成。

RQ1-RQ4: 结果与能说到哪里

RQ	冻结结果	判定	允许的结论
RQ1	3 个配对 seed; control/FME 有效候选率 73.3%/23.3%; 3 条开发 claim、4 个承认反例	质量门未过	机制记录更完整, 但当前实现降低有效候选率; 应先修生成约束
RQ2	TSP 0.83%; CVRP 5.95%; 各 3 seed	方向性支持	结果感知检索可能有帮助, 且高度问题依赖; 不能排除检索量或关键词效应
RQ3	完整配对: BP 5、TSP 0、CVRP 4; win/tie/loss = 2/4/3	不确定	抽象迁移尚无稳定增益; 缺 TSP 配对, 不能宣布泛化成功
RQ4	DeepSeek 历史 605 runs; 在线预检 403; 历史 JoyAI 与 DeepSeek 协议不同	在线阻塞	可报告 DeepSeek 历史曲线; 不可报告跨模型因果效果

这组结果最重要的价值

第一, 它证明“分析更丰富”与“算法更好”是两个必须分开的评价轴。RQ1 的机制门通过而质量门失败, 正是需要保留的负结果。第二, RQ2 暗示历史注入不是全局开关, 而是问题—证据匹配函数。第三, RQ3 暴露迁移研究最容易犯的错误: 在配对不完整时把局部 win 写成泛化。

收敛不是删到只剩一条漂亮故事, 而是把每条支线变成主线上的可替换部件, 并给它明确的失败退出条件。

— Refactor0830 研究口径

不只看末次进化：看算法潜力

最终 best score 只能回答“是否找到过好候选”；潜力曲线进一步回答“多早找到、是否持续改善、分析是否能预测后续增益”。

质量潜力曲线

对最小化问题，以初始基线 J_0 和预算 b 内最优值 $J^*(b)$ 定义 $Q(b) = (J_0 - J^*(b)) / \max(|J_0|, \epsilon)$ ，并在统一预算区间计算 normalized AUC。

问题	历史 runs	质量 AUC	首次达到 5% 的 run	最终最优改进
BP-online	192	0.796	1	83.07%
TSP	206	0.078	1	8.48%
CVRP	207	0.078	4	8.60%

BP 的高 AUC 来自很早发现并保持大幅改进；TSP/CVRP 的最终改进接近，但 CVRP 到达 5% 阈值更慢。这种差异在只看最终 best 时会消失。

分析潜力曲线

历史资产未在看到结果前冻结“预测效果与置信度”，因此本轮不能诚实估计分析潜力。新实现的 `AnalysisRecord` 已要求在评估前记录 observation、hypothesis、predicted effect、probability、regime、risk、cheapest falsification 与 evidence hash。下一 cohort 才能计算：

- 方向准确率、Spearman 相关与 top-k hit：分析能否排序潜力候选；
- Brier score / calibration：置信度是否可信；
- counterexample decision value：分析是否能及时停止无效路线；
- analysis-to-gain efficiency：单位分析成本换来的真实质量增益。

本轮明确把“无法估计”写入结果，而不是从已经看到 outcome 的事后文本反推分析准确率。这是防止自证循环的关键边界。

| 模型配置正确，在线权限尚未满足

随附 PDF 明确了 OpenAI Chat Completions 兼容协议；本地配置已完成且密钥仅保存在 Git 忽略的 .env 中。

配置项	值 / 状态
Endpoint	https://model-router.edu-aliyun.com/v1/chat/completions
Authorization	Bearer <MODEL_ROUTER_API_KEY> ；真实值不进入报告与 Git
模型标识规则	PDF 要求精确的 symbol/model_code
当前推定标识	deepseek/deepseek-v4-flash ；需以账号模型广场实际 symbol 为准
预检结果	HTTP 403 · model_not_found_or_no_permission

阻塞如何解释

原始短名 deepseek-v4-flash 会被网关拒绝为格式错误，说明请求已到达 Model Router。改为若干 symbol/model_code 候选后返回 403，且 PDF 示例模型在当前账号下同样返回 403；GET /v1/models 不可用。证据更符合“账号尚未授权或真实 marketplace symbol 未知”，而不是本地 provider 代码错误。

解除阻塞的最小动作

在 Model Router 模型广场为该 API key 开通 DeepSeek V4 Flash，并复制页面显示的完整 symbol/model_code ；只需更新本地 MODEL_ROUTER_MODEL 后重跑 preflight 与冻结 2×2 manifest。无需再次重构代码。

| 结论、证据边界与下一步

截至本版的完成状态

Phase	交付	状态
1	分支、Provider、.env.example、执行契约、脱敏预检证据	完成
2	FME 单主线、EOH/RAG 适配器、三问题注册表、去活跃支线	完成
3	问题栈、前瞻分析、冻结冷启动、双潜力指标	完成
4	RQ1-RQ4 冻结历史重放与结果资产	离线完成；RQ4 在线 cohort 被 403 阻塞
5	人审报告、PDF、Draw.io 源图与预览	完成

下一轮只做三件事

- 1. 先修 RQ1 的有效候选率：把结构化分析用于生成约束与最小证伪，而不是仅增加反思文本长度；退出条件是有效候选率仍显著低于 control。
- 2. 补齐 RQ2/RQ3 的关键对照：加入 shuffled history 与 TSP 抽象迁移完整配对；不增加新框架。
- 3. 权限开通后一次性跑 RQ4：冻结 Controller × Model 的 2×2 manifest，统一问题、seed、候选评估预算与温度，报告主效应和交互效应。

STOP RULE

任何方向若不能转化为更好的反馈、记忆、泛化、质量或复现能力，或在最小验证预算内未改善潜力曲线，就退出活跃主线并转为历史资产。

| 复现索引与参考文献

A.1 关键资产

- `agent_records/contracts/refactor0830_execution_contract_v1.json` : 本轮执行边界。
- `eoh_rag/fme/mainline.py` : 收敛后的运行时组合。
- `eoh_rag/fme/analysis.py` 、 `cold_start.py` 、 `potential.py` : 问题栈、冷启动与潜力指标。
- `eoh_rag_workspace/experiments/manifests/refactor0830_rq1_rq4_offline_replay_v1.json` : 重放 manifest。
- `eoh_rag_workspace/reports/refactor0830_phase4/rq1_rq4_offline_replay.json` : 机器可读结果。
- `agent_records/calibrations/model_router_deepseek_v4_flash_preflight_20260830.json` : 脱敏 API 预检证据。

A.2 文献

1. EoH: [Evolution of Heuristics](#).
2. ReEvo: [Reflective Evolution of Heuristics](#).
3. FunSearch: [Mathematical discoveries from program search with large language models](#).
4. EPS: [Evolutionary Program Synthesis with LLMs](#).
5. Self-Refine: [Iterative Refinement with Self-Feedback](#).
6. Reflexion: [Language Agents with Verbal Reinforcement Learning](#).
7. LLaMEA: [A Large Language Model Evolutionary Algorithm](#).
8. AlphaEvolve: [A coding agent for scientific and algorithmic discovery](#).

A.3 审阅提示

本报告不包含 API key、原始模型响应、缓存或不可比较的跨 cohort 拼接。所有百分比来自冻结 JSON；“方向性支持”“不确定”“在线阻塞”均为正式结论的一部分，而非待隐藏的异常。