

— 自动科研 · 最终验收报告

# Q3 v2、跨问题迁移 与组件归因报告

60 个主实验 run 与 20 个自动追加归因坐标均已完成。Q3 获得方向性支持；自动探索进一步支持双卡互补或上下文交互。

Codex 执行代理

版本 V3.0 · 2026.07.13

auto-algo-opt · feat/q3-v2-cross-transfer

# | 目录

01 执行结论

---

02 Q3 v2 结果

---

03 跨问题迁移结果

---

04 胜出卡组件归因

---

05 完整性与运行成本

---

06 工程修复与证据链

---

07 交接与下一步

# | 执行结论

preflight 与 Proxy 门禁通过后，Q3 30/30、Cross 30/30 正式 run 均为 **ok**。系统再依据 Q3 结果自动选择最高信息增益方向，完成 20 个单卡组件归因坐标；统计严格按 problem + seed 显式配对，失败和不完整坐标均原样保留。

| 工作流   | 完成度                 | 正式判定                          |
|-------|---------------------|-------------------------------|
| Proxy | 6 / 6               | 全部门禁通过                        |
| Q3 v2 | 30 / 30; 10 对       | directional_support           |
| Cross | 30 / 30; 9 / 15 完整对 | inconclusive                  |
| 组件归因  | 20 / 20; 12 有效      | supports_pair_complementarity |
| 最佳代码  | Q3 3; Cross 4; 组件 2 | AST、held-out 与敏感信息检查通过        |

核心判断

answer 策略卡在 BP 5k 主指标上获得方向性支持；任一单卡均不足以解释双卡优势，支持互补或上下文交互。跨问题抽象迁移因固定 Core 完整性不足，仍不能确认。

# 策略卡机制得到方向性支持

主指标为 BP held-out HiFo 5k C100 gap，越低越好。10 个 seed 全部形成 pure / generic / answer 三臂配对；判定只使用预注册方向性规则，不使用 p 值。

| arm     | runs | median 5k gap | 有效候选率 |
|---------|------|---------------|-------|
| pure    | 10   | 3.9825        | 100%  |
| generic | 10   | 3.9530        | 100%  |
| answer  | 10   | 2.7965        | 100%  |

## 配对判定

answer 相对 pure 的 paired gain 定义为  $\text{pure} - \text{answer} : \text{median gain} = 0.7275$ ，win/tie/loss = 7/0/3。计划规定 answer 获胜至少 7 个 seed 即为 directional\_support，因此结论成立。

generic 仅用于机制诊断：它与 pure 的中位差接近零。结果支持“答案型策略卡”而不是“任意增加上下文”带来方向性改善。

## 可审计输出

已生成 q3\_pairs.csv、q3\_summary.json、decision.json、manifest.lock.json、environment.json、紧凑 run 索引与 3 份最佳代码；原始 prompt、响应和认证信息不进入 Git。

# | 迁移收益暂不能确认

两臂为 local\_only 与 mixed\_abstract。每个 problem × seed 必须在固定 Core 的全部实例上产生有限且可行的 gap，才允许计算 suite score 与 relative gain。

| problem        | 完整配对  | median relative gain | 次要检验           |
|----------------|-------|----------------------|----------------|
| BP Online      | 5 / 5 | 0.0000%              | raw p = 1.0000 |
| TSP Construct  | 0 / 5 | N/A                  | 不执行            |
| CVRP Construct | 4 / 5 | -1.9962%             | 不执行            |

## 全局规则

全局单侧 Wilcoxon 需要 15/15 完整配对，且每个问题必须达到 5/5。本轮只有 9/15，故 p 值为 N/A，正式状态为 inconclusive；可计算配对中的 win/tie/loss 为 2/4/3，但不用于越过完整性门槛。

## 为何不删样本

TSP 每臂 60 个固定实例评测中仅 32 个可行，28 个触发有界 held-out timeout；CVRP mixed 49/50 可行。有限样本的描述性 median gap 可报告，但不能把 timeout 或不可行实例删除后重新定义 Core score。

### 解释边界

本轮不是“证明迁移无效”，而是“固定 Core 证据不足以判定”。对大规模 TSP 的稳定评测合同必须先于下一次正式检验。

# | 双卡优势来自组合，而非任一单卡

Q3 的 10 个 answer run 实际都选择 harmonic 与 residual-poly 两张卡。自动决策器因此冻结相同 10 个 seed、代数、种群、算子和 held-out，仅把 answer 拆成 harmonic-only 与 residual-poly-only 两臂。

| arm                | 有效坐标   | 首次成功   | median valid gap |
|--------------------|--------|--------|------------------|
| harmonic-only      | 9 / 10 | 7 / 10 | 4.0770           |
| residual-poly-only | 3 / 10 | 3 / 10 | 4.0770           |

## 与正式 Q3 的同 seed 比较

answer 对 harmonic-only 为 7胜1平1负；answer 对 residual-poly-only 为 3胜0平0负。harmonic-only 对 pure 为 2/2/5, residual-poly-only 对 pure 为 0/1/2。20 个坐标共发起 39 次预设尝试，8 个失败坐标均在 3 次尝试后以 failed\_after\_retries 留档。

这不是严格加性协同证明。单卡实验同时缩短了上下文并改变候选选择空间，因此正式表述是“支持卡片互补或上下文交互”。若需分离机制，必须预注册等长度、等候选数对照。

自动决策价值

这一步把“answer 有效”推进到“胜出组合的任一单卡都不足以解释收益”，比继续重复共享池对照更能缩小机制假设空间。

# | 完整性与运行成本

## 运行矩阵

| suite | 坐标             | 有效最终候选 | 累计 run-hours | median runtime |
|-------|----------------|--------|--------------|----------------|
| Q3    | 30 / 30        | 180    | 16.27 h      | 1,921 s        |
| Cross | 30 / 30        | 180    | 11.49 h      | 1,055 s        |
| 组件归因  | 20 / 20; 12 有效 | 53     | 10.51 h      | 1,977 s        |

Cross 中 28 个 run 一次成功, 2 个 TSP seed 在修复 held-out 运行合约后重启一次。组件归因严格使用最多 3 次尝试, 失败率本身作为生成稳定性证据, 未继续补抽。全部坐标数量与冻结 manifest 一致。

## 数据与环境锁

- Q3 与组件归因锁定同一 HiFo 5k 文件 SHA-256; Cross 锁定 BP 3 份、TSP 12 份、CVRP 10 份数据 SHA-256。
- environment.json 仅包含 git commit、Python、Provider 名称、endpoint host、模型、并发数、数据哈希和起止时间。
- run\_index.compact.json 删除 output\_dir 等本机路径; 最佳代码每 problem/arm 最多一份。

## 历史对抗候选缺口

605-run 冻结快照没有 failures\_<problem>.jsonl。证据包明确写入 needs\_human\_review 与 missing\_failures\_files, 并保留空候选; 没有从成功代码或运行日志臆造失败模式。

# 工程修复与证据链

正式运行暴露的问题均先复现、后修复、再恢复 cohort；没有通过放宽统计规则掩盖运行缺陷。

| 提交      | 作用                                |
|---------|-----------------------------------|
| c729679 | 修复 OpenCode preflight 认证合同        |
| 9770176 | 保证 cohort 可执行                     |
| 19d59d1 | 提高 Cross evaluator 超时以覆盖 spawn 开销 |
| 0e0de3d | held-out 仅评估最终候选                  |
| bce7c1c | TSP held-out 单实例 30 秒隔离上限         |
| 5ef5cc0 | 增加正式证据导出器与配对统计                    |
| 5366d3f | 冻结 Q3 胜出卡组件归因实验                   |
| 47189d1 | 固化 Q3 v2 正式证据                     |

## 验证纪律

每轮代码修改均执行 git status、git diff/check、定向或全量测试、显式 git add、英文 conventional commit 与 git push。敏感 key 只在进程环境中短暂使用，未写入 manifest、日志证据或提交文件。

组件归因是 Q3 获得方向性支持后，由预设自动门禁选出的最高信息增益实验。证据导出器显式允许读取最终失败坐标，但只从有效坐标导出最佳代码，避免把失败洗成成功。



## | 交接与下一步

### 证据入口

- 实验协议: docs/experiments/gated\_strategy\_card\_experiments.md
- Q3: reports/strategy\_experiments/q3\_v2/q3\_report.md
- Cross: reports/strategy\_experiments/cross\_problem\_transfer/cross\_report.md
- 组件: reports/strategy\_experiments/q3\_card\_components/component\_report.md
- 交接: HANDOFF\_Q3\_CROSS.md

### 可重复导出

```
python scripts/export_strategy_experiment_evidence.py --repository-root .
python -m pytest tests/test_strategy_evidence_export.py -q
python -m pytest -q
python -m compileall -q eoh_rag official_eoh scripts
git diff --check
```

### 研究下一步

最高价值的后续工作有两条，必须重新预注册后再执行：其一，用等长度、等候选数对照分离双卡互补与上下文效应；其二，冻结对大规模 TSP 有稳定预算上限的新 Core，再独立重跑完整 15 对 Cross。不得补抽组件失败坐标，也不得把本轮残缺 Cross 配对拼接进新实验。

#### 最终状态

Proxy 6/6、60 个主实验 run 与 20 个自动探索坐标均已完成并形成可审计证据。Q3 与组件归因结论可用；Cross 保持 inconclusive，等待新的完整协议。